

Shift-Invert 幂法的拉普拉斯算子求解方法：使用 Neural Operator

目标问题

我们希望通过 **shift-invert 幂法** 来求解 **拉普拉斯算子的中间特征值**。具体来说，我们考虑以下的拉普拉斯特征值问题：

$$-\Delta u(x) = \lambda u(x), \quad (x \in \Omega),$$

其中， Δ 是 **拉普拉斯算子**， Ω 是定义域， $u(x)$ 是特征函数， λ 是特征值。

shift-invert 方法

1. 定义移位算子：

首先，我们考虑 **移位算子** $T_\sigma = (A - \sigma I)^{-1}$ ，其中：

- $A = -\Delta$ 是拉普拉斯算子，
- σ 是移位参数，通常选为与目标特征值接近的值。

移位算子的特征值为：

$$\mu_n = \frac{1}{\lambda_n - \sigma},$$

其中 λ_n 是原算子的特征值。通过 **shift-invert 方法**，我们可以逐步收敛到离 σ 最近的特征值及其对应的特征函数。

幂法的应用

我们利用 **幂法** 来计算 **最大特征值** 对应的特征函数。其基本步骤如下：

1. 初始状态：

给定一个初始猜测 u_0 ，通常是随机选取的初始向量。

2. 迭代更新：

每次迭代时，使用幂法进行更新：

$$u_{t+1} = \frac{T_\sigma u_t}{\|T_\sigma u_t\|_{L^2}},$$

这个操作会将 u_t 向离 σ 最近的特征函数收敛。随着迭代次数增加， u_t 会逐步接近目标特征函数。

3. Rayleigh 商估计特征值：

在每次迭代后，我们可以计算 **Rayleigh 商**：

$$\hat{\lambda} = \frac{\langle u_t, A u_t \rangle}{\langle u_t, u_t \rangle}.$$

Rayleigh 商的值会逐步收敛到目标特征值。

Neural Operator 为什么适用

在传统的 **shift-invert** 幂法中，我们每次迭代都需要计算 $(A - \sigma I)^{-1}$ 来得到 w ，这是一种迭代运算，非常耗时，特别是对于复杂的几何形状和大规模问题。

为了提高效率，我们可以通过 **Neural Operator**（神经算子）来直接从 $u(x)$ 预测对应的解 $w(x)$ ，避免了每次反复计算算子运算的步骤。

使用 Neural Operator 的理由

1. 避免每次迭代计算 w ：

在传统方法中，每次求解 w 都需要应用 $(A - \sigma I)^{-1}$ 迭代计算。而 **Neural Operator** 通过训练神经网络，使其能够直接根据 $u(x)$ 推理出 $w(x)$ ，避免了反复计算算子的过程。

2. 高效推理：

一旦网络完成训练，我们可以 **通过一次前向传播** 来得到 $w(x)$ ，这大大提高了计算效率。相比传统方法的多次迭代，神经网络的推理速度非常快，适合实时应用或大规模计算。

3. 适应复杂边界条件：

神经网络能够通过训练自动适应不同的边界条件和几何形状，无需显式修改计算过程。这对于实际应用中，尤其是具有复杂边界的几何问题，非常有用。

4. 跨域能力：

神经网络经过训练后，能够适应不同的域和条件，一次训练后可以在多个不同的测试域中进行高效推理，而无需重新求解每个域的解。

Neural Operator 训练方案

1. 目标方程：

我们希望通过 **Neural Operator** 来训练一个网络，直接从 $u(x)$ 预测 $w(x)$ ，即求解方程：

$$(A - \sigma I)w(x) = u(x).$$

通过神经网络，我们可以直接从 $u(x)$ 计算出 $w(x)$ ，避免了传统方法中每次都应用算子 $(A - \sigma I)^{-1}$ 的过程。

2. 神经网络架构：

- **输入：** $u(x)$ ，即当前的特征函数。
- **输出：** $w(x)$ ，即通过神经网络推理得到的解。
- 我们可以使用多层感知器（MLP）来表示 $w(x)$ ，并通过最小化 **PDE 残差** 来训练网络。

3. 损失函数：

- 我们通过最小化 **PDE 残差** 来训练网络：

$$\mathcal{L}_{\text{int}} = \mathbb{E}_{x \in \Omega} \left[(-\Delta w(x) - \sigma w(x) - u(x))^2 \right].$$

- **边界条件损失：**对于 Dirichlet 边界条件 $w(x) = 0$ 在边界上，我们添加边界损失：

$$\mathcal{L}_{\text{bc}} = \mathbb{E}_{x_b \in \partial\Omega} [w(x_b)^2].$$

- **最终损失函数：**

$$\mathcal{L} = \mathcal{L}_{\text{int}} + \omega_{\text{bc}} \mathcal{L}_{\text{bc}},$$

其中 ω_{bc} 是边界损失的权重。

4. 外层迭代：

每次外层迭代时，使用训练得到的 $w(x)$ 进行归一化得到新的 $u(x)$ ，即：

$$u_{t+1} = \frac{w}{\|w\|_{L^2}},$$

然后计算新的 **Rayleigh 商** 和 **残差**，来监控迭代过程的收敛情况。

停止条件

1. Rayleigh 商收敛:

在每次外层迭代中, 计算 Rayleigh 商:

$$\hat{\lambda} = \frac{\int_{\Omega} \|\nabla u\|^2}{\int_{\Omega} u^2}.$$

当 Rayleigh 商的变化量小于预设阈值时, 停止迭代:

$$\left| \hat{\lambda}(u_{t+1}) - \hat{\lambda}(u_t) \right| < \epsilon_1.$$

2. 特征函数稳定性:

当特征函数 u_t 的变化非常小, 即:

$$\|u_{t+1} - u_t\|_{L^2} < \epsilon_2,$$

停止迭代。

3. 残差收敛:

计算残差:

$$\mathcal{R}_t = \left\| (A - \sigma I)u_t - \hat{\lambda}(u_t)u_t \right\|_{L^2}.$$

当残差小于预设阈值时, 停止迭代:

$$\mathcal{R}_t < \epsilon_3.$$

4. 最大迭代次数:

如果达到最大迭代次数 T_{\max} , 则强制停止。